README del proyecto

Proyecto integrador M1 - InsightReach | EDA, API Yelp y Web Scraping cultural

Autora: Bárbara Magdaleno

En este proyecto analicé una base de clientes, consulté información externa de restaurantes mediante Yelp y sumé una dimensión cultural a través de la extracción de contenido público de Wikipedia. Organicé los tres avances en notebooks separados y utilicé los resultados para formular propuestas de segmentación y marketing.

1. Objetivo y alcance

Mi objetivo fue revisar la calidad de los datos de clientes, enriquecer el análisis con información de negocios locales y sumar contexto cultural de la ciudad seleccionada. Elegí Miami como ciudad principal porque está presente en la base y fue la ciudad utilizada en la consulta de Yelp. Para la actividad de navegación con Selenium seleccioné Chicago como segunda ciudad, que también aparece en la base de clientes.

La información cultural se utiliza como contexto cualitativo. No la uno fila por fila con los clientes ni la interpreto como una característica individual de cada persona, porque no existe una clave común entre las fuentes.

2. Estructura de la entrega

Carpeta / archivo	Contenido
Avances/Notebooks/Avance_EDA.ipynb	Avance 1: carga, exploración, limpieza y tabulación. También contiene el análisis descriptivo del Avance 3.
Avances/Notebooks/Avance_API_Yelp.ipynb	Avance 2: autenticación, consulta a Yelp Business Search, revisión del JSON, transformación y exportación.
Avances/Notebooks/3_WebScraping.ipynb	Nuevo avance: extracción de la sección cultural de Miami en Wikipedia y navegación automatizada con Selenium.
Datos/	Base anonimizada, resultados CSV del EDA y Yelp, metodología y fuentes. Incluye Datos/WebScraping/Resultados_WebScraping (CSV/TXT) y las cinco capturas en Datos/WebScraping/evidencias_webscraping/.
Documentacion/README.docx y README.pdf	Descripción del proyecto, resultados, metodología, instrucciones y limitaciones.
Documentacion/Recomendaciones.docx y Recomendaciones.pdf	Versión editable y PDF con segmentos, propuestas de marketing, contexto cultural y plan de evaluación.

3. Qué hice en cada avance

3.1. Avance 1 - Análisis exploratorio de datos (EDA)

Cargué la base de clientes con Pandas y revisé sus dimensiones, columnas, tipos de datos, estadísticas, valores faltantes y posibles duplicados. Elegí Miami y filtré los registros para explorar con mayor detalle sus variables. Identifiqué edades fuera del rango de referencia y frecuencias negativas; las marqué como faltantes en lugar de eliminar personas. Conservé las frecuencias iguales a cero. También generé tablas y gráficos para describir

variables demográficas, preferencias, consumo de licor, membresías, medios de pago y variables numéricas disponibles.

La base original tiene 30.000 registros y 13 columnas. Miami reúne 3.186 clientes, equivalentes al 10,62% del total. En la base no existen variables de duración de sesión ni calificaciones de clientes; por eso no inventé esas columnas ni las reemplacé por otras.

3.2. Avance 2 - Integración con Yelp API

Conecté el endpoint Yelp Business Search mediante una clave API y autenticación Bearer. La clave se lee desde Google Colab Secrets con el nombre YELP_API_KEY y no queda escrita en el código ni dentro del ZIP. Revisé la respuesta JSON y separé los datos generales de los negocios de las categorías para evitar repetir un negocio cuando tiene más de una categoría.

La búsqueda informó 5.900 resultados posibles y recuperé 100 negocios en dos solicitudes de hasta 50 resultados. La extracción generó 270 relaciones de categorías; después de eliminar pares repetidos de negocio y categoría quedaron 202 relaciones únicas. De los 100 negocios, 83 informan Miami y 17 localidades cercanas.

3.3. Avance 3 - Análisis integrado y Web Scraping

En el notebook de EDA respondí las preguntas de negocio indicadas en la consigna mediante tablas, gráficos y análisis descriptivo. Analicé la distribución por ciudad, los estratos, el gasto estimado, las preferencias, las membresías, la relación entre frecuencia y gasto, la relación entre ingresos y gasto y el consumo de alcohol según la edad. También identifiqué perfiles de mayor gasto y construí cuatro segmentos para Miami.

En el notebook 3_WebScraping incorporé contenido cultural del artículo de Miami en Wikipedia. En la ejecución adjunta, registrada el 5 de noviembre de 2026 a las 04:29 UTC, la página respondió HTTP 200. Extraje 16 párrafos de la sección Culture, con 1.079 palabras, agrupados en siete subsecciones: Introducción de cultura (2 párrafos, 223 palabras), Venues (3, 100), Events (4, 202), Music and performing arts (1, 61), Museums and visual arts (1, 61), Cuisine (2, 207) y Dialect (3, 225). La extracción se realizó desde la versión en inglés del artículo y cada registro conserva la URL de origen y la fecha de consulta.

También utilicé Selenium para automatizar la navegación: abrí el artículo de Miami, busqué Chicago desde el buscador interno, cambié el tema visual de day a night y navegué al artículo de Chicago en español. La ejecución guardó cinco capturas y un registro CSV. La verificación del tema devolvió guardado=True, tema=night y claseOscura=True; la página capturada se muestra con fondo oscuro. En el panel lateral de la captura aparece un indicador de color que no se sincroniza visualmente con esa preferencia, por lo que conservo también la comprobación técnica del DOM y la salida de Selenium. Los resultados y las evidencias reales de esta ejecución están incluidos en Datos/WebScraping/.

4. Resultados principales del análisis

Indicador	Resultado
Clientes por ciudad	Chicago tiene 5.384 clientes; Miami tiene 3.186.
Estratos socioeconómicos	Medio: 9.325 (31,08%); Alto: 9.038 (30,13%); Bajo: 6.161 (20,54%); Muy Alto: 5.476 (18,25%).
Gasto estimado por período registrado	Miami presenta la media más alta: 225,88 unidades de la base.
Ingresos y gasto estimado	La correlación de Pearson es aproximadamente 0,71. Es una asociación y no demuestra causalidad.
Preferencias en Miami	Mariscos: 26,94%; Vegetariano: 23,95%; Carnes: 16,81%; Vegano: 12,57%, sobre respuestas válidas.
Perfil de mayor gasto	El 25% superior reúne 7.080 clientes. Sus preferencias más frecuentes son Carnes, Vegetariano y Mariscos.
Membresías premium	Chicago tiene más membresías en cantidad (2.215); Miami tiene la proporción más alta (53,17%).

Indicador	Resultado
Edad y consumo de licor	Edad media de 45,99 entre quienes declaran consumir y 53,64 entre quienes no.
Segmentación de Miami	Clasifiqué 2.997 clientes con ambas variables válidas usando medianas de frecuencia (5) y gasto por comida (31,59).
Extracción cultural de Wikipedia	HTTP 200; 16 párrafos; 1.079 palabras; 7 subsecciones; consulta del 05/11/2026 a las 04:29 UTC.

5. Cómo interpreto e integro las fuentes

La integración entre clientes y Yelp es contextual: comparé las preferencias declaradas con las categorías asociadas a negocios. Por ejemplo, Mariscos representa el 26,94% de las preferencias válidas en Miami, mientras que seis de los 83 negocios cuya ciudad informada es Miami tienen la categoría Seafood. En esa muestra no aparecen etiquetas Vegetarian ni Vegan. Esto no demuestra que esos restaurantes no ofrezcan platos vegetarianos o veganos: las categorías de Yelp no describen necesariamente todo el menú.

La información cultural de Wikipedia amplía la interpretación del contexto local. En la sección Culture aparecen referencias a influencias gastronómicas latinoamericanas y caribeñas, cocina Floribbean, platos de origen cubano y presencia de restaurantes de mariscos. Uso esos elementos para formular ideas que después deberían validarse con los menús, la oferta real de los negocios y los datos de clientes. No deduzco la identidad cultural, el idioma ni las preferencias individuales de una persona a partir de su ciudad.

6. Cómo reproducir el trabajo

1. Instalar las dependencias indicadas en requirements.txt con: pip install -r requirements.txt.
2. Abrir Avances/Notebooks/Avance_EDA.ipynb en Google Colab o Jupyter y ejecutar las celdas en orden.
3. Abrir Avances/Notebooks/Avance_API_Yelp.ipynb. Para repetir la consulta, crear el Secret YELP_API_KEY en Google Colab y habilitar su acceso al notebook. No escribir la clave directamente en el código.
4. Abrir Avances/Notebooks/3_WebScraping.ipynb. Antes de ejecutar, reemplazar CONTACTO por un correo de contacto válido en el User-Agent. Ejecutar las celdas en orden: instalación de librerías, descarga y extracción cultural, exportación, instalación/inicio de Chrome en Colab y automatización con Selenium. El notebook incluye la instalación del navegador para el entorno Colab utilizado en esta ejecución.
5. Si trabajo en Colab y la carpeta del proyecto está en Google Drive, puedo configurar DIRECTORIO_PROYECTO para guardar los resultados culturales en Datos/WebScraping. En la ejecución que adjunto, Colab guardó los resultados en /content/Resultados_WebScraping y las capturas en evidencias_webscraping; luego incorporé ambos conjuntos al proyecto, manteniendo una estructura ordenada dentro de Datos/WebScraping.
6. En la entrega incluyo los resultados generados en Colab: el CSV detallado de los párrafos, el resumen por subsección, el TXT con el texto extraído y el registro de evidencias de Selenium. Las cinco capturas se encuentran en Datos/WebScraping/evidencias_webscraping/. Si vuelvo a ejecutar el notebook, los archivos se vuelven a generar y debo revisar la fecha y el contenido actualizado.

7. Limitaciones y criterios de uso

- La base no aclara el período de frecuencia_visita ni la moneda de promedio_gasto_comida. Por eso calculé frecuencia_visita × promedio_gasto_comida y lo denominé gasto estimado por período registrado; no lo presento como gasto mensual confirmado.
- Los 100 resultados de Yelp son una muestra de búsqueda, no el universo de restaurantes de Miami. Además, 17 informan localidades cercanas.
- No existe una clave común que permita identificar qué cliente visitó qué restaurante. La comparación entre clientes y Yelp es contextual, no una unión individual.

- Las categorías de Yelp no garantizan que un negocio ofrezca o no un plato específico. Es necesario revisar los menús.
- La extracción cultural es una captura puntual de la sección Culture disponible en inglés y no representa toda la cultura de Miami ni las preferencias de su población. Los 16 párrafos y 1.079 palabras describen el contenido que devolvió la página el 5 de noviembre de 2026; Wikipedia puede actualizarse y una nueva ejecución puede producir resultados distintos. Para decisiones comerciales reales, contrastaría la información cultural con fuentes locales y oficiales.
- Las correlaciones no prueban causalidad y las recomendaciones son hipótesis que deben probarse y medirse antes de ampliarse.
- La cultura o el idioma no se utilizan para inferir atributos sensibles de clientes. Las campañas deben basarse en preferencias declaradas, comportamiento observado y opciones de comunicación elegidas por las personas.

8. Fuentes

- **Base de clientes:** Base entregada para el proyecto integrador; se incluye una copia sin datos de contacto en Datos/.
- **Yelp Business Search:** https://docs.developer.yelp.com/reference/v3_business_search
- **Yelp Places Authentication:** https://docs.developer.yelp.com/docs/places-authentication
- **Wikipedia - Miami:** https://en.wikipedia.org/wiki/Miami
- **Wikipedia - Chicago:** https://en.wikipedia.org/wiki/Chicago
- **Wikipedia - Chicago en español:** https://es.wikipedia.org/wiki/Chicago
- **Política de User-Agent de Wikimedia:** https://foundation.wikimedia.org/wiki/Policy:Wikimedia_Foundation_User-Agent_Policy
- **Política de acceso y límites de Wikimedia:** https://www.mediawiki.org/wiki/Wikimedia_APIs/Access_policy
- **Límites de uso de Wikimedia:** https://www.mediawiki.org/wiki/Wikimedia_APIs/Rate_limits
- **Selenium - Esperas:** https://www.selenium.dev/documentation/webdriver/waits/